Tecnológico Nacional de México / Instituto Tecnológico de Orizaba

División de Estudios de Posgrado e Investigación

Maestría en Sistemas Computacionales

Desarrollo de una plataforma computacional para la construcción y enriquecimiento de un corpus paralelo náhuatl–español con análisis morfológico orientado al apoyo de sistemas de traducción automática

Presenta: Israel Alberto Huerta Fernández

Director: Dr. Giner Alor Hernández

Codirector: Dr. Isaac Machorro Cano

Orizaba, Veracruz

11 de noviembre del 2026

Jurado

Dr. Giner Alor Hernández
Presidente

Dr. Mario Andrés Paredes Valverde
Secretario

Dr. Jose Luis Sánchez Cervantes
Vocal

Dr. Isaac Machorro Cano
Vocal suplente

Agenda

01 · Objetivo de la presentación

02 · Planteamiento del problema

03 · Objetivo general

04 · Objetivos específicos

05 · Análisis de tecnologías

06 · Solución propuesta

07 · Cronograma de actividades

08 · Conclusiones

09 · Compromisos a futuro

10 · Referencias

Objetivo de la presentación

Dar a conocer los avances del anteproyecto de tesis, principalmente el análisis de tecnologías, la solución propuesta y el cronograma de actividades.

Planteamiento del problema

Capturar



Audio y metadatos organizados desde el origen

Planteamiento del problema

Capturar



Audio y metadatos
organizados desde el origen

Relacionar



Audio, textos
y anotaciones
vinculados entre sí

Planteamiento del problema

Capturar



Audio y metadatos organizados desde el origen

Relacionar



Audio, textos y anotaciones vinculados entre sí

Validar



Revisión lingüística con historial de cambios

El reto: integrar estos procesos en un corpus paralelo confiable.

Objetivo general

Desarrollar una plataforma computacional para la construcción y enriquecimiento de un **corpus paralelo náhuatl–español**, con análisis morfológico y validación lingüística, orientado al apoyo de futuros sistemas de traducción automática.

Objetivos específicos

1. **Analizar** tecnologías para la gestión de recursos lingüísticos náhuatl–español.

Objetivos específicos

1. **Analizar** tecnologías para la gestión de recursos lingüísticos náhuatl–español.
2. **Diseñar** la arquitectura de la plataforma móvil para la construcción del corpus.

Objetivos específicos

1. **Analizar** tecnologías para la gestión de recursos lingüísticos náhuatl–español.
2. **Diseñar** la arquitectura de la plataforma móvil para la construcción del corpus.
3. **Desarrollar** la plataforma para recopilar, enriquecer y validar datos lingüísticos.

Objetivos específicos

1. **Analizar** tecnologías para la gestión de recursos lingüísticos náhuatl–español.
2. **Diseñar** la arquitectura de la plataforma móvil para la construcción del corpus.
3. **Desarrollar** la plataforma para recopilar, enriquecer y validar datos lingüísticos.
4. **Construir** un corpus paralelo náhuatl–español con los recursos recopilados y validados.

Objetivos específicos

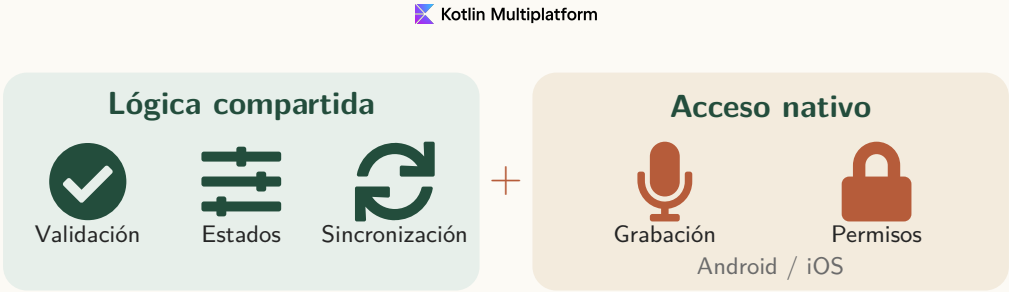
1. **Analizar** tecnologías para la gestión de recursos lingüísticos náhuatl–español.
2. **Diseñar** la arquitectura de la plataforma móvil para la construcción del corpus.
3. **Desarrollar** la plataforma para recopilar, enriquecer y validar datos lingüísticos.
4. **Construir** un corpus paralelo náhuatl–español con los recursos recopilados y validados.
5. **Evaluar** la plataforma mediante casos de estudio como prueba de concepto.

Análisis de tecnologías (1/5): Desarrollo Móvil

Tecnologías y lenguajes de programación	Logotipos
Kotlin Multiplatform Kotlin	Kotlin Multiplatform
Flutter Dart	
React Native JavaScript / TypeScript	
.NET MAUI C#	

Fuentes: Kotlin Multiplatform [1]; Compose Multiplatform (interfaces) [2]; Flutter [3]; React Native [4]; .NET MAUI [5].

¿Por qué Kotlin Multiplatform en este proyecto?



Compartir la lógica. Conservar lo nativo.

Kotlin Multiplatform [1]. Selección de arquitectura para esta propuesta.

Análisis de tecnologías (2/5): Servicios Backend

Tecnologías y lenguajes de programación	Logotipos
Spring Boot Java	 
NestJS TypeScript	 
Django Python	 
ASP.NET Core C#	 

Fuente: documentación de Spring Boot [6].

Análisis de tecnologías (3/5): Persistencia y Audio

Bases de datos

Tecnología	Logo
MongoDB	
PostgreSQL	

Almacenamiento de audio

Tecnología	Logo
MinIO	
Amazon S3	
Firebase Storage	

Fuentes: documentación de MongoDB [7] y MinIO [8].

Análisis de tecnologías (4/5): Audio y PLN

Tecnología	Logo
Hugging Face Transformers	
Whisper	
Vosk	
spaCy	spaCy

Fuente: documentación de Hugging Face Transformers [9].

Análisis de tecnologías (5/5): Metodología de Desarrollo de Software

Metodología	Icono
Scrum	
Mobile-D	
Kanban	
Extreme Programming	

Fuente para Scrum: Schwaber y Sutherland, The Scrum Guide [10].

Alternativas de solución

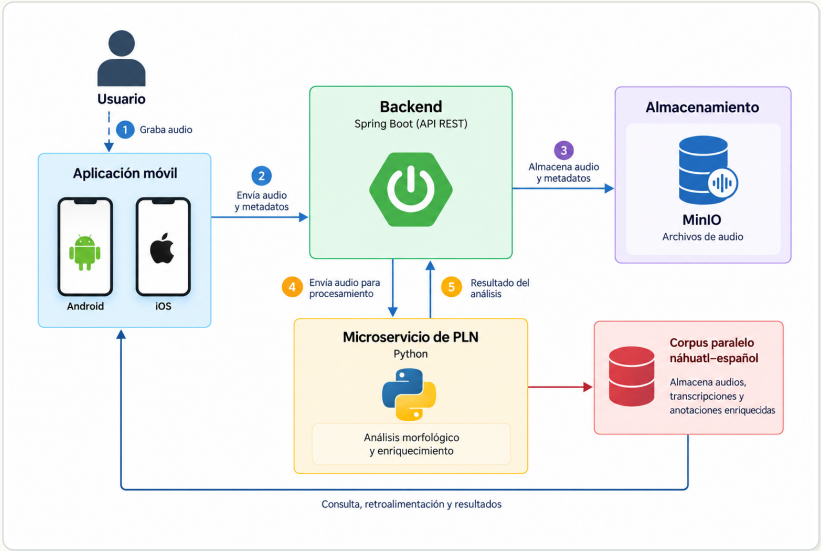
Alt.	Móvil / lenguaje	Backend / lenguaje	Base de datos	Audio	Audio y PLN	Metodología
1	Kotlin Multi-platform (KMP) Kotlin	Spring Boot Java	MongoDB	MinIO	Hugging Face Transformers	Scrum
2	Flutter Dart	NestJS TypeScript	PostgreSQL	Firebase Storage	Whisper	Mobile-D
3	React Native JavaScript / TypeScript	Django Python	MongoDB	Amazon S3	Vosk	Kanban
4	.NET MAUI C#	ASP.NET Core C#	PostgreSQL	MinIO	spaCy	Extreme Programming
5	Flutter Dart	Django Python	MongoDB	Amazon S3	Hugging Face Transformers	Scrum

Solución propuesta

Componente	Tecnología seleccionada
Framework móvil multiplataforma	**Kotlin Multiplatform (KMP)**
Desarrollo backend	**Spring Boot**
Sistema gestor de base de datos	**MongoDB**
Almacenamiento y gestión de audio	**MinIO**
Procesamiento de audio y PLN	**Hugging Face Transformers**
Lenguaje de programación	**Kotlin**
Metodología de desarrollo	**Scrum**

Fuentes: KMP [1]; Spring Boot [6]; MongoDB [7]; MinIO [8]; Transformers [9]; Scrum [10]. Referencia para publicación de corpus: Kaggle Datasets [11].

Arquitectura propuesta



Cronograma de actividades (1/4)

Actividad
1. Analizar las tecnologías de información y comunicación aplicables al desarrollo de una plataforma móvil para la construcción y enriquecimiento de un corpus paralelo náhuatl–español.
2. Analizar los métodos, técnicas y recursos lingüísticos utilizados para la recopilación, organización, transcripción y gestión de datos de corpus en lenguas de bajos recursos.
3. Redactar el capítulo 1 de la tesis.
4. Redactar el capítulo 2 de la tesis.

Cronograma de actividades (2/4)

Actividad
5. Diseñar un prototipo no funcional de la aplicación móvil, considerando los principios de usabilidad, accesibilidad y experiencia de usuario para la recopilación y clasificación de registros de audio.
6. Redactar el capítulo 3 de la tesis.
7. Diseñar la arquitectura y los servicios necesarios para la recopilación, almacenamiento, organización, sincronización y gestión de los registros de audio y sus metadatos asociados.

Cronograma de actividades (3/4)

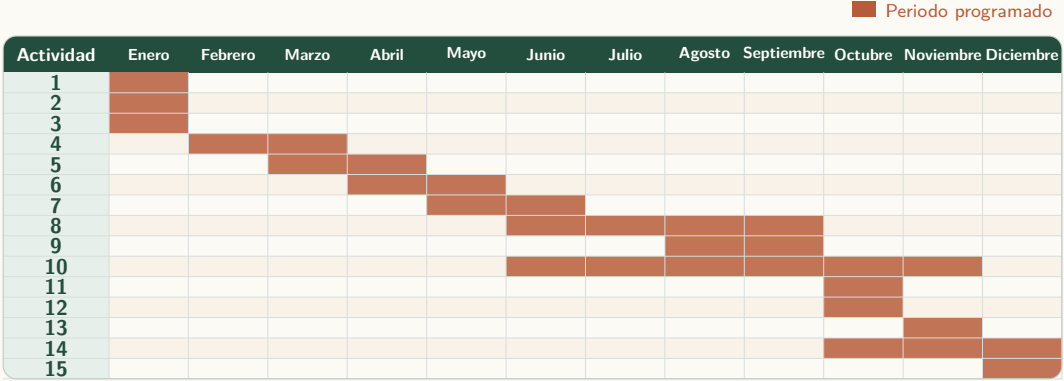
Actividad
8. Desarrollar la aplicación móvil multiplataforma para la recopilación, clasificación y gestión de registros de audio destinados a la construcción y enriquecimiento del corpus paralelo náhuatl–español.
9. Redactar el capítulo 4 de la tesis.
10. Realizar la estancia académica.
11. Redactar el capítulo 5 de la tesis.
12. Efectuar las correcciones necesarias en la redacción y documentación de la tesis.

Cronograma de actividades (4/4)

Actividad
13. Evaluar el funcionamiento de la plataforma mediante casos de estudio como prueba de concepto, considerando la recopilación, organización y gestión de los registros de audio destinados al corpus paralelo náhuatl–español.
14. Presentar el examen TOEFL.
15. Realizar el examen de grado.

Cronograma de actividades: 2027

Responsable del proyecto: Israel Alberto Huerta Fernández



Conclusiones

- La revisión realizada identifica la **disponibilidad limitada** de recursos lingüísticos computacionales para **lenguas de bajos recursos**.

Conclusiones

- La revisión realizada identifica la **disponibilidad limitada** de recursos lingüísticos computacionales para **lenguas de bajos recursos**.
- La **diversidad lingüística del náhuatl** forma parte de las consideraciones necesarias para la **construcción y enriquecimiento del corpus**.

Conclusiones

- La revisión realizada identifica la **disponibilidad limitada** de recursos lingüísticos computacionales para **lenguas de bajos recursos**.
- La **diversidad lingüística del náhuatl** forma parte de las consideraciones necesarias para la **construcción y enriquecimiento del corpus**.
- Los antecedentes revisados proporcionan elementos para abordar la **recopilación, organización**, **análisis y validación** de datos lingüístico.

Compromisos a futuro

- Cumplir en tiempo y forma con las actividades del cronograma.

Compromisos a futuro

- Cumplir en tiempo y forma con las actividades del cronograma.
- Atender en tiempo y forma las observaciones realizadas al anteproyecto de tesis por parte del jurado.

Compromisos a futuro

- Cumplir en tiempo y forma con las actividades del cronograma.
- Atender en tiempo y forma las observaciones realizadas al anteproyecto de tesis por parte del jurado.
- Concluir en tiempo y forma el anteproyecto de tesis.

Referencias

1/3

[1] JetBrains, “Kotlin Multiplatform.” [En línea]. Disponible en: https://kotlinlang.org/docs/multiplatform.html.

[2] JetBrains, “Compose Multiplatform.” [En línea]. Disponible en: https://www.jetbrains.com/lp/compose-multiplatform/.

[3] Flutter, “Flutter Documentation.” [En línea]. Disponible en: https://docs.flutter.dev/.

[4] Meta, “React Native Documentation.” [En línea]. Disponible en: https://reactnative.dev/.

Referencias

2/3

[5] Microsoft, ".NET MAUI Documentation." [En línea]. Disponible en: https://learn.microsoft.com/dotnet/maui/.

[6] Spring, "Spring Boot." [En línea]. Disponible en: https://spring.io/projects/spring-boot.

[7] MongoDB, "MongoDB Documentation." [En línea]. Disponible en: https://www.mongodb.com/docs/.

[8] MinIO, "MinIO Documentation." [En línea]. Disponible en: https://min.io/.

Referencias

3/3

[9] Hugging Face, “Transformers Documentation.” [En línea]. Disponible en: https://huggingface.co/docs/transformers/.

[10] K. Schwaber y J. Sutherland, “The Scrum Guide,” 2020. [En línea]. Disponible en: https://scrumguides.org/.

[11] Kaggle, “Datasets.” [En línea]. Disponible en: https://www.kaggle.com/datasets.

Gracias

¿Preguntas?